PROYECCION HIDROLOGICA

Sistema de Predicciones ML del Portal Energetico

Analisis tecnico del modelo predictivo, su arquitectura,
limitaciones y propuesta de mejora mediante PINN-LSTM

CONTEXTO DEL ANALISIS

- Fecha de analisis: Junio 2026
- Fenomeno evaluado: El Nino — Probabilidad >95% de fortalecimiento
- Horizonte predictivo: 31 de agosto 2026 (aprox. 2.5 meses)
- Meta de seguridad XM: 80% de capacidad util en embalses
- Estado actual: 73.82% (6% por debajo de la meta)

RESULTADO CLAVE DE LA PREDICCION

Prediccion modelo Prophet + SARIMA (Ensemble): 77.31% para 31 agosto 2026

El modelo proyecta recuperacion (+3.49 pp) pero NO alcanza la meta del 80%
La proyeccion climatica del IDEAM reduce aun mas las probabilidades de exito

1. QUE ES UN MODELO DE MACHINE LEARNING

Un modelo de Machine Learning (ML) es un sistema computacional que aprende patrones a partir de datos historicos para hacer predicciones sobre eventos futuros. A diferencia de los modelos tradicionales basados en ecuaciones fisicas o reglas fijas, un modelo ML descubre relaciones complejas y no lineales entre variables sin necesidad de que un humano programe explicitamente esas reglas.

En el contexto del Portal Energetico del MME, el modelo ML analiza series temporales de datos energeticos (generacion, demanda, precios, niveles de embalse) y aprende patrones estacionales, tendencias y ciclos para proyectar valores futuros. El modelo no 'conoce' las leyes de la fisica; aprende correlaciones estadisticas desde los datos.

1.1 Tipos de modelos utilizados

El sistema emplea tres familias de modelos segun la naturaleza de cada metrica:

PROPHET (Meta/Facebook) — Modelo aditivo de series temporales
Componentes: Tendencia + Estacionalidad + Eventos especiales
Ventaja: Maneja datos faltantes, detecta changepoints automaticamente
Uso: Series con estacionalidad pronunciada (embalses, hidraulica, biomasa)

SARIMA (Auto-ARIMA) — Modelo estadistico clasico
Componentes: AR(p) + I(d) + MA(q) + estacionalidad (P,D,Q)m
Ventaja: Fundamentacion estadistica rigurosa, intervalos de confianza robustos
Uso: Series con alta autocorrelacion (termica, eolica)

LIGHTGBM (Microsoft) — Gradient Boosting
Tipo: Arboles de decision con boosting
Ventaja: Captura relaciones no lineales, feature importance interpretable
Uso: Series complejas/volatiles (demanda, precio bolsa, solar, eolica, perdidas)

2. QUE ES UN MODELO PREENTRENADO

Un modelo preentrenado es un modelo de ML que ya ha sido entrenado con un conjunto de datos previo y puede ser reutilizado para tareas similares sin necesidad de entrenar desde cero. Ejemplos famosos incluyen GPT-4 (preentrenado con texto de internet) o ResNet (preentrenado con imagenes de ImageNet).

Sin embargo, NUESTRO MODELO NO ES PREENTRENADO en el sentido tradicional. El sistema del Portal Energetico reentrena los modelos COMPLETAMENTE DESDE CERO cada 3 dias, utilizando los datos historicos mas recientes de la base de datos PostgreSQL. Esto significa que el modelo se adapta continuamente a los cambios del sistema.

CARACTERISTICAS DE NUESTRO MODELO

- NO usa modelos genericos preentrenados (como GPT o BERT)
- SI se entrena con datos especificos del SIN colombiano
- Reentrenamiento automatico: cada 3 dias (dom/mie/sab 2:00 AM)
- Datos de entrada: metrics de XM (2020-2026, con backfill 2000-2019)
- Pipeline completo: carga → preparacion → entrenamiento → validacion → almacenamiento

2.1 Pipeline de entrenamiento (18-25 minutos)

PASO 1: CARGA DE DATOS (3-5 segundos)

Query PostgreSQL: SELECT fecha, valor_gwh FROM metrics
WHERE metrica = 'PorcVoluUtilDiar' AND entidad = 'Sistema'
Rango: ultimos 365-730 dias de datos historicos

PASO 2: PREPARACION (1-2 segundos)

- Interpolacion de fechas faltantes
- Winsorizacion de outliers (>3 desviaciones estandar)
- Formateo para Prophet (columnas 'ds' y 'y')
- Formateo para SARIMA (serie temporal con indice DatetimeIndex)

PASO 3: ENTRENAMIENTO PARALELO (180-300s por fuente)

- Prophet: optimizacion MAP (30-60 segundos)
- SARIMA: busqueda stepwise de parametros (120-180 segundos)
- Validacion hold-out: ultimos 30 dias como prueba
- Calculo de pesos ensemble: inversos al MAPE

PASO 4-6: ALMACENAMIENTO Y VALIDACION

- INSERT 450 registros (90d x 5 fuentes) con UPSERT
- Verificacion: MAPE < 7%, coverage 90-98%, no negativos
- Invalidacion automatica de cache Redis

3. POR QUE USAMOS ESTE MODELO Y NO OTRO

La seleccion del modelo Prophet + SARIMA (Ensemble) para embalses no fue arbitraria. Se evaluaron 6 familias de modelos mediante validacion cruzada temporal con datos historicos del SIN (2020-2024), comparando MAPE (Error Porcentual Absoluto Medio) y tiempo de entrenamiento.

3.1 Comparativa de modelos evaluados

Modelo	MAPE	Tiempo	Fortalezas	Debilidades
Prophet	3.5-5%	30-60s	Estacionalidad, interpretable	Cambios abruptos
SARIMA	4.0-6%	120-180s	Autocorrelacion, IC rigurosos	Estacionariedad req.
LSTM	5.0-8%	1800-3600s	Patrones complejos	Requiere 10000+ obs
XGBoost	6.0-9%	45-90s	Robusto a outliers	No captura temporal
ARIMA	7.0-10%	60-120s	Modelo clasico probado	Sin estacionalidad mult.
Holt-Winters	8.0-12%	5-10s	Simple y rapido	Estacionalidad constante

El ensemble Prophet + SARIMA logro MAPE = 3.2% para embalses, superando a ambos modelos individuales. Esta precision es suficiente para planificacion operativa del SIN (umbral aceptable: MAPE < 7%).

3.2 Justificacion del ensemble

La combinacion ponderada aprovecha las fortalezas complementarias:

PROPHET APORTA
- Deteccion automatica de tendencias de largo plazo
- Modelado flexible de estacionalidad anual (ciclos de lluvias)
- Manejo de changepoints (nuevas plantas, politicas energeticas)
- Tolerancia a datos faltantes (comunes en datos XM)

SARIMA APORTA
- Captura de dependencia serial de corto plazo (AR/MA)
- Intervalos de confianza con fundamentacion estadistica rigurosa
- Modelado de estacionalidad semanal (patrones de demanda)
- Correccion por errores previos (componente MA)

ENSEMBLE: PROMEDIO PONDERADO

y_ensemble(t) = w_prophet * y_prophet(t) + w_sarima * y_sarima(t)
w_i = (1/MAPE_i) / sum(1/MAPE_j) [pesos inversos al error]
Resultado: MAPE 3.2% < 3.8% (Prophet solo) < 4.2% (SARIMA solo)

4. ERRORES DEL MODELO Y POR QUE LOS TENEMOS

A pesar de que el modelo ensemble Prophet + SARIMA logra un MAPE de 3.2% para embalses —excelente para planificacion operativa— existen limitaciones fundamentales que el sistema NO puede superar con la arquitectura actual. Estas limitaciones son inherentes al tipo de modelo y a los datos de entrada.

4.1 Error 1: No captura eventos climaticos extremos

El modelo Prophet + SARIMA aprende patrones ESTADISTICOS de los datos historicos. Si en los ultimos 6 anos (2020-2026) no ha ocurrido un El Nino intenso, el modelo NO tiene informacion suficiente para anticipar como se comportaran los embalses durante dicho evento. El modelo asume que el futuro se parecera al pasado reciente.

EJEMPLO CONCRETO: EL NINO 2026-2027

- El modelo predice 77.31% para agosto 2026 basandose en la estacionalidad historica
- PERO la proyeccion climatica del IDEAM indica deficit de lluvias en cuencas clave
- El modelo NO incluye el indice ONI (Nino Oscilacion del Sur) como variable de entrada
- Resultado: prediccion optimista que no refleja el riesgo real del fenomeno

4.2 Error 2: No incorpora leyes fisicas

El modelo es puramente estadistico. No conoce la ecuacion de potencia hidraulica P = rho * g * Q * H * eta, ni el efecto fotoelectrico de los paneles solares, ni el limite de Betz para aerogeneradores. Esto significa que puede generar predicciones fisicamente inconsistentes (ej: generacion hidraulica sin agua suficiente).

CONSECUENCIA: PREDICCIONES FISICAMENTE INCONSISTENTES

- El modelo puede predecir generacion hidraulica alta sin considerar caudales reales
- No respeta el balance de potencia: suma generaciones != demanda + perdidas
- No puede identificar configuraciones pre-crisis (umbrales de caudal, ONI, embalses)
- Intervalos de confianza se amplian excesivamente (>50%) para horizontes >90 dias

4.3 Error 3: Datos de entrada limitados

El modelo solo utiliza la serie temporal de embalses (% capacidad util) como entrada. No incorpora variables climaticas exogenas como precipitacion IDEAM, irradiancia NASA POWER, velocidad del viento, ni el indice ONI. Esto reduce drasticamente su capacidad predictiva ante condiciones anomalas.

VARIABLES NO UTILIZADAS ACTUALMENTE

- Precipitacion IDEAM (cuencas Magdalena, Cauca, Nechi)
- Irradiancia solar NASA POWER (Costa Caribe, La Guajira)
- Velocidad del viento IDEAM (Alta Guajira, parques eolicos)
- Indice ONI (Nino Oscilacion del Sur) de NOAA
- Caudales afluentes reales (Q en la ecuacion hidraulica)

5. PROPUESTA DE MEJORA: PINN-LSTM

Basado en la propuesta de investigacion de Melissa Cardona (Trabajo de Grado, Fisica, Universidad del Atlantico, 2026), se propone reemplazar el modelo estadistico actual por un modelo hibrido Physics-Informed Neural Network (PINN) con arquitectura recurrente LSTM.

5.1 Que es una PINN-LSTM

Una Physics-Informed Neural Network (PINN) es una red neuronal que incorpora las leyes de la fisica como terminos de penalizacion en su funcion de perdida. La arquitectura LSTM (Long Short-Term Memory) captura dependencias temporales de largo alcance. La combinacion PINN-LSTM permite:

VENTAJAS DE PINN-LSTM SOBRE PROPHET+SARIMA

- Incorpora ecuaciones fisicas de generacion (hidraulica, solar, eolica, termica)
- Respeta el balance de potencia: suma generaciones = demanda + perdidas
- Cuantifica incertidumbre con Monte Carlo Dropout (intervalos bien calibrados)
- Identifica umbrales pre-crisis mediante analisis de sensibilidad inversa
- Utiliza variables climaticas exogenas (ONI, precipitacion, irradiancia, viento)

5.2 Ecuaciones fisicas incorporadas

HIDROELECTRICA: P = rho * g * Q * H * eta

rho = densidad del agua (1000 kg/m3)
g = aceleracion gravitacional (9.81 m/s2)
Q = caudal volumetrico (m3/s) — variable de entrada IDEAM
H = altura hidraulica (m) — parametro de infraestructura
eta = eficiencia de turbina (~0.90 en turbinas modernas)

SOLAR FOTOVOLTAICA: P = eta(T) * A * G

eta(T) = eficiencia dependiente de temperatura
A = area del panel (m2) — capacidad instalada
G = irradiancia solar (W/m2) — variable NASA POWER

EOLICA: P = Cp * 0.5 * rho * A * v^3

Cp = coeficiente de potencia (<= 0.593, limite de Betz)
v = velocidad del viento (m/s) — variable IDEAM
rho = densidad del aire (kg/m3)

6. FUNCION DE PERDIDA HIBRIDA

El componente central del modelo PINN-LSTM es la funcion de perdida hibrida que combina el error de prediccion con los residuos de las ecuaciones fisicas. Esto garantiza que las predicciones sean energeticamente consistentes.

FUNCION DE PERDIDA TOTAL

L = L_datos + lambda_h * L_hidro + lambda_pv * L_solar + lambda_w * L_eolica + lambda_reg * L_reg

L_datos: Error cuadratico medio ponderado sobre el vector de potencias objetivo
L_hidro, L_solar, L_eolica: Residuos de las ecuaciones fisicas de cada fuente
L_reg: Regularizacion por dropout (prevencion de overfitting)

6.1 Balanceo adaptativo de pesos

El ajuste de los pesos lambda es el problema practico mas critico en el entrenamiento de PINNs. Se adopta el metodo de Wang et al. (2021) que normaliza gradientes por tarea, eliminando la necesidad de ajustar los pesos como hiperparametros estaticos.

FORMULA DE BALANCEO ADAPTATIVO

lambda_k <- max_j(|grad_theta L_j|) / |grad_theta L_k|

Donde |grad_theta L_k| es la norma media del gradiente de la k-esima perdida respecto a los parametros de la red. Este mecanismo normaliza automaticamente la magnitud de cada termino de perdida en el espacio de gradientes.

6.2 Cuantificacion de incertidumbre

Se implementa Monte Carlo Dropout con N = 200 pases estocasticos por punto de prediccion. La varianza epistemica captura la incertidumbre del modelo ante regiones poco pobladas del espacio de entradas, como las condiciones extremas asociadas a eventos El Nino intensos.

VARIANZA EPISTEMICA

Var_epistemica = (1/N) * sum((P_hat(n) - P_mean)^2) para n = 1..N

Intervalos de confianza al 90% y 95% estimados por cuantiles empiricos
Calibracion evaluada mediante diagramas de fiabilidad

7. ANALISIS DE SENSIBILIDAD INVERSA

Una vez entrenado el modelo PINN-LSTM, se aplica analisis de sensibilidad inversa para identificar las configuraciones de variables de entrada que conducen a estados de crisis (deficit de generacion respecto a la demanda).

7.1 Definicion de deficit relativo

DEFICIT RELATIVO

delta_t = (P_dem,t - (P_h,t + P_pv,t + P_eol,t + P_term,t)) / P_dem,t

Umbral de crisis tau*: percentil 90 de la distribucion empirica de delta_t
durante los episodios de racionamiento documentados (2009-2010, 2015-2016)

7.2 Configuraciones criticas

Se busca el conjunto C(tau*) de configuraciones de variables de entrada que producen deficit >= tau*. Esto se resuelve mediante optimizacion por gradientes proyectados (L-BFGS-B con restricciones de caja), usando diferenciacion automatica del grafo computacional de la red.

VARIABLES DE ENTRADA ANALIZADAS

- Caudales afluentes Q_t (IDEAM) — variable fisica determinante
- Niveles de embalse agregado (XM)
- Indice ONI (NOAA) — senal climatica global
- Demanda nacional P_dem,t (XM)
- Precio de bolsa (XM) — proxy de estres del sistema
- Irradiancia solar G_t (NASA POWER)
- Velocidad del viento v_t (IDEAM)

7.3 Sensibilidad de la prediccion

RANKING DE SENSIBILIDAD

S_j = (1/|T_crisis|) * sum(|d(delta_t)/d(x_j,t)|) para t en T_crisis

Donde T_crisis es el conjunto de instantes etiquetados como pre-crisis
y x_j,t es la j-esima variable de entrada en el tiempo t.
El ranking de S_j identifica los factores desencadenantes de mayor influencia.

8. RESULTADOS ESPERADOS Y BENEFICIOS

La implementacion del modelo PINN-LSTM en el Portal Energetico del MME traeria mejoras significativas en la calidad de las predicciones y en la capacidad de anticipacion de crisis energeticas.

MEJORAS CUANTITATIVAS ESPERADAS

- Reduccion de MAPE en embalses: 3.2% → < 2.5% (incorporando ONI y caudales)
- Reduccion de MAPE en demanda: 29.1% → < 8% (modelo fisico + climatico)
- Intervalos de confianza bien calibrados: coverage 90-95% (vs 85-90% actual)
- Horizonte predictivo extendido: 90 dias → 365 dias con confianza moderada
- Identificacion de umbrales pre-crisis con 30-90 dias de anticipacion

MEJORAS CUALITATIVAS

- Predicciones fisicamente consistentes (respetan leyes de conservacion)
- Cuantificacion de incertidumbre ante eventos extremos (El Nino, sequias)
- Alertas tempranas basadas en umbrales de variables de entrada
- Interpretabilidad: el modelo 'sabe' por que predice lo que predice
- Replicabilidad en sistemas similares (Brasil, Peru, Ecuador, Centroamerica)

IMPACTO EN LA TOMA DE DECISIONES

- Planificacion del despacho economico con mayor horizonte temporal
- Gestion proactiva de reservas hidricas (protocolos de conservacion)
- Activacion temprana de generacion termica de respaldo
- Informacion para politicas publicas de seguridad energetica
- Reduccion del riesgo de racionamiento y sus costos socioeconomicos

9. CONCLUSIONES Y RECOMENDACIONES

El sistema actual de predicciones ML del Portal Energetico (Prophet + SARIMA Ensemble) es funcional y cumple con los requisitos de planificacion operativa para condiciones normales. Sin embargo, presenta limitaciones criticas ante eventos climaticos extremos como El Nino, debido a su naturaleza puramente estadistica y la ausencia de variables climaticas exogenas.

CONCLUSIONES CLAVE

1. El modelo actual es ADECUADO para condiciones normales (MAPE 3.2% en embalses)
2. El modelo actual es INSUFICIENTE para eventos extremos (no captura El Nino)
3. La solucion propuesta (PINN-LSTM) incorpora fisica y variables climaticas
4. El analisis de sensibilidad inversa permite alertas tempranas de crisis
5. La inversion en este modelo representa un seguro contra racionamientos futuros

RECOMENDACIONES INMEDIATAS

1. INTEGRAR el indice ONI como regresor en el modelo actual de embalses
2. INCORPORAR precipitacion IDEAM y caudales como variables de entrada
3. DESARROLLAR prototipo PINN-LSTM para una metrica piloto (ej: embalses)
4. VALIDAR contra episodios historicos (2009-2010, 2015-2016)
5. ESTABLECER alianza con Universidad del Atlantico para implementacion

REFERENCIAS TECNICAS

- Cardona Navarro, M. (2026). Estudio de la generacion de potencia del SIN mediante redes neuronales profundas y validacion Monte Carlo. Trabajo de Grado, Programa de Fisica, Universidad del Atlantico.

- Documentacion tecnica del Portal Energetico MME:
  server/docs/tecnicos/DOCUMENTACION_TECNICA_IA_ML.md
  server/domain/services/predictions_service_extended.py